

Proyecto Integrador de Sistemas de Recuperación de Información. Documentación

Kelen Alfaro García , Adriana Boué García, Carlos Alejandro Mazorra Matos

1 Definición del Dominio Seleccionado

El dominio seleccionado es cultura y entretenimiento, con énfasis en películas y series.

El sistema recupera documentos que describen obras audiovisuales (título, sinopsis, género, reparto, dirección, país y año), extraídos desde fuentes web especializadas mediante el crawler/scrapper del proyecto

1.1 Objetivo de Recuperación

- Permitir búsquedas semánticas en lenguaje natural sobre películas y series.
- Recuperar resultados relevantes, aunque la consulta no use exactamente las mismas palabras del documento.

1.2 Alcance del Corte 1

- Construcción de un corpus inicial del dominio.
- Generación de representaciones vectoriales densas (embeddings).
- Ranking básico por similitud coseno.

1.3 Alcance del Corte 2

- Refinamiento y depuración del corpus documental (1,029 obras audiovisuales con metadatos expandidos).
- Implementación de un modelo de Generación Aumentada por Recuperación (RAG) para ofrecer respuestas sintetizadas en lenguaje natural.
- Incorporación de un módulo de expansión web (web_search) para enriquecer las respuestas con información externa actualizada cuando la consulta lo amerita.
- Ajuste de la infraestructura de almacenamiento mutando a un formato JSON estandarizado para los metadatos y un índice vectorial renovado.

2 Documentación del Modelo de Recuperación Implementado

2.1 Tipo de Modelo

Se implementó un modelo de recuperación neuronal no básico basado en embeddings con Sentence Transformers.

Modelo usado: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2

Este modelo produce un vector denso para cada documento y para cada consulta. La recuperación se hace comparando vectores en el espacio latente.

En términos de IR neuronal, este enfoque corresponde a un esquema bi-encoder (dual encoder):

- Un encoder transforma documentos a vectores.
- El mismo encoder transforma la consulta a un vector.
- La relevancia se estima con una función de similitud vectorial.

Este diseño permite indexar el corpus una vez y reutilizar los embeddings para múltiples consultas.

2.2 Modelo Híbrido: Motivación y Arquitectura

Si bien el enfoque puramente neuronal es efectivo, se ha evolucionado hacia un modelo híbrido que combina embeddings densos con indexación léxico-estadística (TF-IDF) para obtener mayor precisión y cobertura.

¿Por qué híbrido? Un modelo híbrido combina dos paradigmas complementarios:

1. Recuperación densa (embeddings neurales):
 - Captura relaciones semánticas profundas entre consulta y documentos.
 - Funciona bien con parafraseos y sinónimos.
 - Entiende intencionalidad semántica detrás de la consulta.
2. Recuperación léxico-estadística (TF-IDF):
 - Excelente para coincidencias de términos exactos y frecuencia.
 - El efecto IDF captura la importancia de palabras poco comunes.
 - Soporta búsquedas por metadatos específicos (directores, países, actores).

Ventajas de la combinación

- Mayor cobertura: Algunos documentos relevantes se recuperan por semántica, otros por exactitud lexical.
- Mayor precisión: En consultas que mencionan tipos explícitamente ("dame una serie policial"), se aplican restricciones de metadatos.

- Robustez: Si la semántica falla en un ámbito, la lexical compensa (y viceversa).
- Escalabilidad: El índice léxico es ligero y rápido, permitiendo filtrado eficiente antes del ranking neural.

Arquitectura de dos etapas

- Etapa 1: Recuperación de candidatos (híbrida)
 - Búsqueda densa: top-50 resultados por similitud coseno de embeddings.
 - Búsqueda léxico-estadística: puntuación TF-IDF para términos de consulta.
 - Fusión adaptativa: combinación ponderada neural más léxico con peso ajustable (α).
 - Restricciones de tipo: filtro o penalización para consultas que especifican "serie" o "película".
- Etapa 2: Re-ranking neuronal (CrossEncoder)
 - Los candidatos se reevalúan con un modelo CrossEncoder especializado.
 - El CrossEncoder analiza directamente cada par (consulta, documento) en lugar de embeddings independientes.
 - Fusión final: score base combinado con score de re-ranking mediante fusión ponderada para mayor precisión.

2.3 Flujo Implementado en el Proyecto

1. Recolección y Limpieza: Se procesan los documentos a través del crawler/scrapper modificado, generando el archivo unificado en data/dataset.json.
2. Preprocesamiento: Construcción de una cadena semántica por documento unificando: título + géneros + directores + actores + plot
3. Indexación Dual:
 - Densa: Codificación neuronal del corpus con SentenceTransformers y almacenamiento de vectores en bd/movies_vectors.index.
 - Léxica: Procesamiento tradicional (limpieza, tokenización, stemming) y persistencia en index/index.json.
4. Flujo de ejecución RAG en tiempo de consulta:
 - El pipeline es orquestado por rag_module/pipeline.py.
 - La consulta del usuario entra al retriever_wrapper.py, el cual consulta los índices y extrae el top-K de documentos candidatos empleando internamente NeuralRetriever.search_with_web_expansion()
 - Si el umbral de confianza local es menor a un factor predefinido (ej. 0.72) o la cobertura léxica es baja, se dispara automáticamente

el `web_expander.py` para recabar información en la red, integrando lo scrapeado temporalmente.

- Se transmite la información recuperada y la consulta a `generator.py`, quien ensambla un *prompt* y lo inyecta a un Modelo de Lenguaje Local (Ollama - Neural-Chat).
- El modelo sintetiza los datos, formulando la respuesta conversacional definitiva que lee el usuario final.

Implementación Principal y Ejecución:

La orquestación actual centralizó las operaciones en `main.py`, permitiendo ejecutar el recabado y la interfáz final a través de comandos escalonados:

- Crawler y Scraper: Se pueden invocar con `python main.py crawl` y `python main.py scrape` (que impactan sobre `crawler/crawler.py` y `scraper/scraper.py`).
- Recuperador Híbrido (Base): Configurado principalmente en `neural_based_model/neural_retriever.py`, es el motor base. Para validaciones, puede verificarse aislando el backend con `python run_retrieval_demo.py`.
- Evaluación RAG Asistida: Lanzada mediante `python -m rag_module.run_rag`, abre consola para testeos con Ollama de manera interactiva.
- Ejecución completa: Invocando `python main.py`.

2.4 Función de Ranking

La similitud utilizada es coseno:

$$\text{sim}(q, d) = \frac{\vec{q} \cdot \vec{d}}{|\vec{q}| |\vec{d}|} \quad (1)$$

Donde:

- $\vec{q}$ es el embedding de la consulta.
- $\vec{d}$ es el embedding del documento.

Los documentos se ordenan por valor de similitud descendente.

Interpretación de score:

- Score cercano a 1: alta cercanía semántica entre consulta y documento.
- Score cercano a 0: baja relación semántica.

Procedimiento de ranking implementado:

1. Se obtiene el vector de similitudes para todos los documentos.
2. Se aplica ordenamiento descendente de índices por score.
3. Se recorta al top-k solicitado.
4. Los documentos resultantes se extraen como el "Contexto" relevante que alimentará la etapa de generación final.

Para el ordenamiento se usa una estrategia exacta sobre todo el corpus (no aproximada).

2.5 Análisis de Complejidad y Comportamiento

Si N es el número de documentos y D la dimensión del embedding:

- Costo de indexación inicial: $O(N \cdot C_{enc})$ donde C_{enc} es el costo del encoder por documento.
- Costo por consulta (similitud coseno vectorizada): aproximadamente $O(N \cdot D)$.
- Costo de ordenar resultados completos: $O(N \log N)$.

Para el corpus actual ajustado del corte 2 (1,029 documentos), este costo de clasificación de vectores es de ejecución casi inmediata en CPU. El costo temporal principal en esta nueva iteración ha pasado a concentrarse en la latencia de inferencia propia de la etapa de generación de texto del modelo RAG y el retraso de red producto de posibles consultas web externas.

2.6 Criterios de Desempate y Estabilidad del Ranking

El criterio primario de orden es el score de similitud coseno.

Cuando dos documentos presentan scores idénticos, el orden relativo se define por la jerarquía técnica del arreglo de similitudes, asegurando que el contexto seleccionado para la generación sea estable. Para optimizar esta selección, el sistema prioriza documentos que presenten mayor coincidencia de género con la consulta, mejor completitud en sus metadatos y niveles superiores de popularidad o rating.

2.7 Fortalezas y Limitaciones del Enfoque Actual

Fortalezas del Corte 2:

- Comprensión y Síntesis: Gracias a RAG, el modelo ya no solo recupera datos, sino que redacta respuestas hiladas, explica relaciones complejas y elabora justificaciones en lenguaje humano.

- Cobertura Viva: La integración de un motor de búsqueda web en tiempo real elimina la frontera del dataset estático, permitiendo cubrir estrenos o temas altamente específicos.
- Recuperación Resiliente: La base híbrida neuronal-léxica garantiza un soporte sólido de contexto para el LLM, compensando léxico exacto frente a aproximaciones de parafraseo.

Limitaciones actuales:

- Latencia Global: El tiempo de respuesta se incrementó notablemente (de milisegundos a varios segundos) debido al tiempo requerido por la inferencia del generador (LLM) y las lecturas de los crawlers externos en tiempo real.
- Riesgo de Alucinación Menor: Pese al anclaje en documentos verificados (RAG), existe la posibilidad inherente de que el LLM sufra desviaciones generativas si el prompt recuperado es difuso.

2.8 Justificación Técnica

La migración de un sistema exclusivo de recuperación (Corte 1) a una arquitectura conversacional aumentada (Corte 2) se justifica por la evolución en la interacción hombre-máquina moderna. Un sistema puramente extractivo obliga al usuario a evaluar individualmente múltiples resultados. Al implementar un Pipeline RAG con fall-back a web automática, la plataforma asume el costo cognitivo de analizar los resultados, sintetizando recomendaciones directas, escalando enormemente la calidad percibida de las respuestas y evitando devolver "vacíos" cuando las bases locales no son suficientes.

3 Estadísticas Básicas del Corpus Recopilado

Tras las recientes iteraciones, el corpus ha sufrido una reestructuración, mejorando en riqueza textual.

3.1 Tamaño General del Corpus

Tras el proceso de crawling y scraping realizado para este corte, se ha consolidado un corpus con las siguientes métricas de volumen:

- Cantidad total de documentos: 1029.
- Documentos tipo película: 383.
- Documentos tipo serie: 646.




Fig. 1. Distribución comparativa entre películas y series de TV recopiladas en el dominio de cultura y entretenimiento.

3.2 Análisis de Longitud Textual

Para garantizar que el modelo de recuperación semántica (embeddings) reciba suficiente contexto, se analizó la extensión de la cadena de texto consolidada título + sinopsis. Los resultados actualizados del corpus son:

- Promedio de palabras por documento: 139.75
- Promedio de caracteres por documento: 831.64
- Mínimo de palabras en un documento: 2
- Máximo de palabras en un documento: 429

3.3 Diversidad y Riqueza del Corpus

El dominio de cultura y entretenimiento presenta una alta variabilidad en sus atributos. El análisis de los metadatos extraídos de las fuentes especializadas arroja los siguientes indicadores de diversidad, fundamentales para validar la robustez del sistema de recuperación:

Distribución Temática y Geográfica

- Géneros detectados: Se identificaron 31 categorías únicas. El corpus presenta una marcada predominancia de los géneros Drama (453 documentos) y Comedia (239), seguidos por Animación (223), Aventura (182) y Suspense (170).
- Alcance Global: El sistema integra obras de 109 países de origen. Destaca la hegemonía de producciones de Estados Unidos (518), seguida por una presencia significativa de España (135) y Gran Bretaña (57).




Fig. 2. Distribución de los cinco géneros principales segmentados por país de origen. La visualización permite confirmar la diversidad del corpus y la representatividad de cada categoría dentro de los mercados cinematográficos líderes.

Entidades y Personalidades

- Directores: Se identificaron 382 directores únicos
- Elenco: El corpus cuenta con una base de 2352 actores únicos.

Valoración y Calidad (Ratings)

- Rating promedio: La calificación media de las obras en el corpus es de 3.69.
- Rango de valoración: El conjunto de datos abarca desde obras de alto impacto crítico (1.2) hasta producciones de menor recepción (4.7).




Fig. 3. Distribución de frecuencias de las calificaciones en el corpus.

3.4 Análisis del Rango Temporal

El corpus recolectado presenta una ventana cronológica que permite evaluar el desempeño del sistema ante diferentes contextos de producción audiovisual. Los datos temporales registrados son:

- Año mínimo detectado: 1940
- Año máximo detectado: 2028
- Cobertura temporal: El conjunto de datos abarca un período de 88 años.

3.5 Estructura del Índice Invertido

Para optimizar la recuperación y superar la búsqueda secuencial, se implementó un índice invertido basado en frecuencias de términos. Tras el refinamiento del corpus, la estructura presenta los siguientes indicadores técnicos:

- Tamaño del Vocabulario: Se han indexado un total de 14507 términos únicos tras el proceso de tokenización y stemming.
- Densidad del Índice: En promedio, cada término del vocabulario está vinculado a 5.34 documentos. Esto indica una alta especificidad en el léxico recolectado, lo cual minimiza el ruido en la recuperación.

- Alcance y Frecuencia de Términos: En el análisis de los términos con mayor presencia en el corpus se destacan raíces como 'seri' (683 documentos) y 'eeuu' (566). Asimismo, la presencia de raíces temáticas como 'dram' (463) confirma la coherencia del índice con el género predominante (Drama), asegurando que el sistema recupere contenido alineado con las categorías principales del conjunto de datos.

4 Fuentes Bibliográficas

1. Mitra, B., y Craswell, N. (2018). An Introduction to Neural Information Retrieval. Foundations and Trends in Information Retrieval
2. NLTK Project. NLTK Documentation: Spanish Snowball Stemmer. Recuperado de: <https://www.nltk.org/>
3. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)
4. Hugging Face Documentation: paraphrase-multilingual-MiniLM-L12-v2. Available at: huggingface.co.