

Proyecto Integrador de Sistemas de Recuperación de Información. Documentación

Kelen Alfaro García¹, Adriana Boué García¹, Carlos Alejandro Mazorra Matos¹

¹ Facultad de Matemáticas y Computación, Universidad de la Habana, San Lázaro y L,
Vedado, La Habana, Cuba.

{kelen.alfaro, adriana.boue, carlos.amazorra }@estudiantes.matcom.uh.cu

Resumen. Este artículo presenta el diseño, desarrollo y evaluación de CulturaSearch, un sistema híbrido de recuperación de información enfocado en el dominio de películas y series. La arquitectura propuesta combina un enfoque neural bi-encoder mediante Sentence Transformers para capturar la semántica profunda en lenguaje natural, junto con un índice léxico-estadístico tradicional (TF-IDF) para optimizar la coincidencia exacta de palabras clave y metadatos. El sistema integra un re-ranking fino mediante un Cross-Encoder, un módulo de expansión web automática para paliar la baja cobertura local, y un componente de Generación Aumentada por Recuperación (RAG) con un LLM local para ofrecer respuestas conversacionales.

Palabras clave: Recuperación de información híbrida, Sentence Transformers, Cross-Encoder, Generación Aumentada por Recuperación, Cultura y entretenimiento

1 Definición del Dominio Seleccionado

El dominio seleccionado es cultura y entretenimiento, con énfasis en películas y series. El sistema recupera documentos que describen obras audiovisuales (título, sinopsis, género, reparto, dirección, país y año), extraídos desde fuentes web especializadas mediante el crawler/scrapper del proyecto

1.1 Objetivo de Recuperación

- Permitir búsquedas semánticas en lenguaje natural sobre películas y series.
- Recuperar resultados relevantes, aunque la consulta no use exactamente las mismas palabras del documento.

1.2 Alcance del Corte 1

- Construcción de un corpus inicial del dominio.
- Generación de representaciones vectoriales densas (embeddings).
- Ranking básico por similitud coseno.

1.3 Alcance del Corte 2

- Refinamiento y depuración del corpus documental.
- Implementación de un modelo de Generación Aumentada por Recuperación (RAG) para ofrecer respuestas sintetizadas en lenguaje natural.
- Incorporación de un módulo de expansión web (web_search) para enriquecer las respuestas con información externa actualizada cuando la consulta lo amerita.
- Ajuste de la infraestructura de almacenamiento mutando a un formato JSON estandarizado para los metadatos y un índice vectorial renovado.

1.4 Alcance del Corte 3

- Incorporación de una interfaz visual en Streamlit para facilitar la exploración del corpus mediante búsquedas en lenguaje natural.
- Incorporación del módulo de posicionamiento para ordenar y priorizar los resultados según señales de relevancia, metadatos y criterios visuales.
- Integración de autenticación de usuarios, personalización de resultados y ordenamiento visual para mejorar la interacción con el sistema.
- Implementación de un módulo de evaluación para medir el comportamiento del recuperador mediante métricas de recuperación de información.

2 Documentación del Modelo de Recuperación Implementado

2.1 Tipo de Modelo

Se implementó un modelo de recuperación neuronal no básico basado en embeddings con Sentence Transformers [3]. Modelo usado: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 [4]. Este modelo produce un vector denso para cada documento y para cada consulta. La recuperación se hace comparando vectores en el espacio latente. En términos de IR neuronal, este enfoque corresponde a un esquema bi-encoder (dual encoder) [1]:

- Un encoder transforma documentos a vectores.
- El mismo encoder transforma la consulta a un vector.
- La relevancia se estima con una función de similitud vectorial.

Este diseño permite indexar el corpus una vez y reutilizar los embeddings para múltiples consultas.

2.2 Modelo Híbrido: Motivación y Arquitectura

Si bien el enfoque puramente neuronal es efectivo, se ha evolucionado hacia un modelo híbrido que combina embeddings densos con indexación léxico-estadística (TF-IDF) para obtener mayor precisión y cobertura.

¿Por qué híbrido?:

1. Recuperación densa (embeddings neurales):
 - Captura relaciones semánticas profundas entre consulta y documentos.
 - Funciona bien con parafraseos y sinónimos.
2. Recuperación léxico-estadística (TF-IDF / índice invertido)
 - Excelente para coincidencias exactas de términos y consultas que dependen de palabras clave.
 - Soporta búsquedas por metadatos (directores, actores, país, temporadas).

Ventajas de la combinación

- Mayor cobertura: Algunos documentos relevantes se recuperan por semántica, otros por exactitud lexical.
- Mayor precisión: En consultas que mencionan tipos explícitamente ("dame una serie policial"), se aplican restricciones de metadatos.
- Robustez: Si la semántica falla en un ámbito, la lexical compensa (y viceversa).
- Escalabilidad: El índice léxico es ligero y rápido, permitiendo filtrado eficiente antes del ranking neural.

Arquitectura de dos etapas

- Etapa 1: Recuperación de candidatos (híbrida)
 - Búsqueda densa: se calculan similitudes sobre embeddings y se obtienen top-N candidatos (N es configurable; en código suele usarse valores como 50 por defecto).
 - Búsqueda léxica: se calcula puntuación léxica (TF-IDF / coincidencia de términos) usando el índice en ``index/index.json``.
 - Fusión adaptativa: los scores dense y léxico se combinan con pesos configurables (α) y se aplican boosts/penalizaciones por metadatos (tipo, año, país, actores).
 - Filtrado por tipo: el sistema puede filtrar o penalizar resultados según la intención ("serie" vs "película").
- Etapa 2: Re-ranking neuronal (CrossEncoder)
 - Los candidatos resultantes se reevalúan con un CrossEncoder (re-ranker) que evalúa pares (consulta, documento) para producir un score fino.

- La fusión final combina score base y score de re-ranking mediante ponderación para ordenar la lista definitiva.

2.3 Flujo Implementado en el Proyecto

1. Recolección y Limpieza: Se procesan los documentos a través del crawler/scrapper modificado, generando el archivo unificado en data/dataset.json.
2. Preprocesamiento: Construcción de una cadena semántica por documento unificando: título + géneros + directores + actores + plot
3. Indexación Dual:
 - Densa: Codificación neuronal del corpus con SentenceTransformers y almacenamiento de vectores en bd/movies_vectors.index.
 - Léxica: Procesamiento tradicional (limpieza, tokenización, stemming) [2] y persistencia en index/index.json.
4. Flujo de ejecución RAG en tiempo de consulta:
 - El pipeline es orquestado por rag_module/pipeline.py.
 - La consulta del usuario se pasa al LLM para optimizarla, añadiendo palabras claves y eliminando las que solo serian ruido para el buscador
 - La consulta optimizada entra al retriever wrapper.py, el cual consulta los índices y extrae el top-K de documentos candidatos empleando internamente NeuralRetriever.search_with_web_expansion()
 - Si el umbral de confianza local es menor a un factor predefinido (ej. 0.72) o la cobertura léxica es baja, se dispara automáticamente el web_expander.py para recabar información en la red, integrando lo scrapeado temporalmente.
 - Se transmite la información recuperada y la consulta a generator.py, quien ensambla un *prompt* y lo inyecta a un Modelo de Lenguaje Local (Ollama - Neural-Chat).
 - El modelo sintetiza los datos, formulando la respuesta conversacional definitiva que lee el usuario final.

Implementación Principal y Ejecución:

La orquestación actual centralizó las operaciones en main.py, permitiendo ejecutar el recabado y la interfáz final a través de comandos escalonados:

- Crawler y Scrapper: Se pueden invocar con python main.py crawl y python main.py scrape (que impactan sobre crawler/crawler.py y scraper/scrapper.py).
- Recuperador Híbrido (Base): Configurado principalmente en neural_based_model/neural_retriever.py, es el motor base. Para validaciones, puede verificarse aislando el backend con python run_retrieval_demo.py.

- Evaluación RAG Asistida: Lanzada mediante `python -m rag_module.run_rag`, abre consola para tests con Ollama de manera interactiva.
- Ejecución completa: Invocando `python main.py`.
- Interfaz visual: `app.py` implementa la interfaz en Streamlit.

2.4 Función de Ranking

La similitud utilizada es coseno:

$$\text{sim}(q, d) = \frac{\vec{q} \cdot \vec{d}}{|\vec{q}| |\vec{d}|} \quad (1)$$

Donde:

- $\vec{q}$ es el embedding de la consulta.
- $\vec{d}$ es el embedding del documento.

Módulo de posicionamiento: `positioning_module/ranking.py` es el componente encargado de ajustar el orden final de los resultados, combinando señales de similitud, metadatos y criterios de relevancia visual.

Señal base: la similitud coseno entre embeddings de consulta y documento es una de las señales principales (embeddings calculados con SentenceTransformer).

Procedimiento real implementado:

1. Recuperación inicial por embeddings y por puntuación léxica.
2. Combinación preliminar de scores (neural + léxico) con pesos configurables.
3. Re-ranking con CrossEncoder para refinar orden.
4. Ajustes finales por metadatos (año, país, tipo, actores) aplicados como boosts/penalizaciones.

2.5 Análisis de Complejidad y Comportamiento

Si N es el número de documentos y D la dimensión del embedding:

- Costo de indexación inicial: $O(N \cdot C_{enc})$ donde C_{enc} es el costo del encoder por documento.
- Costo por consulta (similitud coseno vectorizada): aproximadamente $O(N \cdot D)$.
- Costo de ordenar resultados completos: $O(N \log N)$.
- Costo adicional de re-ranking: depende del número de candidatos procesados por el CrossEncoder.
- Costo adicional de expansión web: variable, condicionado por la disponibilidad de la red y por la cantidad de documentos externos recuperados.

En el corpus actual, el cálculo de similitud y ordenamiento se ejecuta con rapidez en CPU. No obstante, el tiempo total de respuesta puede aumentar por la inferencia del modelo generativo local y por la latencia asociada a la expansión web, en caso de activarse.

2.6 Criterios de Desempate y Estabilidad del Ranking

El criterio principal de ordenamiento es la puntuación final obtenida tras combinar señales semánticas, léxicas y de re-ranking. El sistema busca mantener un comportamiento estable en la presentación de resultados, de modo que pequeñas variaciones numéricas no provoquen cambios drásticos en el orden.

En la implementación final (Corte 3), el desempate se apoya en la ordenación interna de los resultados y en la combinación de señales secundarias derivadas de metadatos. Entre estas señales se incluyen coincidencias con actores, géneros, tipo de contenido, país, año y otros atributos relevantes.

El sistema prioriza los siguientes criterios de forma general:

1. Relevancia final combinada.
2. Relevancia semántica base.
3. Coincidencia léxica.
4. Señales de metadatos.
5. Tipo de contenido solicitado.
6. Identificador estable del documento como criterio final de consistencia.

3 Diseño de la Interfaz Visual y Posicionamiento de la Información

La interfaz visual del sistema fue diseñada con el objetivo de facilitar la exploración del corpus de forma clara, jerarquizada e intuitiva. Para ello, se optó por una presentación en tarjetas, donde cada resultado se muestra como una unidad visual independiente que resume los atributos más relevantes del documento: título, tipo de contenido, puntuación, año, valoración y sinopsis.

En términos de distribución visual, la información se organiza siguiendo una jerarquía de atención. En primer lugar, se ubican los elementos asociados a la relevancia de la búsqueda, como la posición en el ranking y la puntuación obtenida. Posteriormente, se presentan los metadatos descriptivos del contenido, lo que permite identificar con rapidez si el documento recuperado responde a la intención de la consulta. Finalmente, la sinopsis aparece como un elemento complementario para profundizar en la comprensión del resultado.

Asimismo, el panel lateral concentra los controles de búsqueda, los parámetros de recuperación y los ejemplos de consultas, con el propósito de separar claramente las acciones de configuración respecto de la visualización de resultados. Esta organización mejora la legibilidad general de la interfaz y favorece una interacción más ordenada con el sistema.

4 Justificación de las Estrategias de Posicionamiento Implementadas

La estrategia adoptada en el proyecto busca un equilibrio práctico entre precisión, cobertura y experiencia de usuario. Se fundamenta en cuatro decisiones principales:

1. Hibridación semántica-léxica: la fusión de señales neurales y léxicas se implementa en `compute_hybrid_fusion` (`positioning_module/ranking.py`) y se controla por el parámetro Alpha. Esta decisión garantiza que el sistema capture intención (embeddings) y, al mismo tiempo, mantenga precisión en búsquedas por entidades o términos exactos (índice léxico).
2. Re-ranking fino con Cross-Encoder: cuando la topología de candidatos presenta ambigüedad, aplicamos un re-ranking por Cross-Encoder y lo mezclamos con el score base mediante `compute_rerank_fusion` y `NeuralRetriever.rerank_candidates`. Así se resuelven empates semánticos y se obtiene mayor coherencia en el top-K final.
3. Prioridad de metadata y frescura: el posicionamiento aplica boosts y penalizaciones explícitas para título, director/creador, actores, temporadas y año (funciones `metadata_match_score`, `actor_alignment_score`, `season_alignment_score`, `year_alignment_score` en `positioning_module/ranking.py`). Además, `_freshness_score` incorpora una señal temporal que favorece contenido más reciente cuando procede.
4. Robustez y cobertura externa: el sistema monitoriza la cobertura léxica local (`query_lexical_coverage`) y, si la confianza es baja, activa `search_with_web_expansion` para traer documentos web adicionales (`web_search/`).

Complementariamente, la personalización (módulo `recommendation_module`) respeta la señal del retriever como prioritaria y re-puntúa resultados usando historial, géneros y vistas, preservando top-N en búsquedas de metadata específica. Para desempates y trazabilidad, el tie-breaker determinista (`build_positioning_tie_breaker`) combina completitud de metadata, match de género y posición original, lo que produce un orden reproducible y explicable.

5 Módulos Adicionales de Recomendación y Evaluación

5.1 Módulo de Recomendación

Además del motor principal de recuperación, el sistema incorpora un módulo de recomendación diseñado para personalizar la experiencia de usuario. Este componente modela un perfil a partir de señales explícitas e implícitas de interacción, como el historial de búsquedas, los contenidos visualizados o marcados como relevantes, y las preferencias derivadas de los géneros, términos y tipos de contenido consultados. A partir de esta representación, el módulo calcula una puntuación de recomendación para

cada documento, combinando características del contenido con información conductual del usuario.

Además, el sistema incluye una modalidad de recomendación sin query explícita. En este caso, en lugar de esperar una búsqueda del usuario, el módulo construye una consulta sintética a partir de su perfil, utilizando sus búsquedas recientes, géneros preferidos, términos más frecuentes y tipo de contenido de mayor interés. Esa consulta se envía al recuperador para obtener candidatos del corpus, y luego se reordenan los resultados priorizando los más afines al perfil, al mismo tiempo que se excluyen o penalizan los documentos ya vistos o clicados.

5.2 Módulo de Evaluación

El proyecto también incluye un módulo de evaluación que permite analizar el comportamiento del recuperador mediante métricas propias de recuperación de información. Para evaluar la efectividad del sistema de recuperación de información en el dominio de series y películas, se diseñó y ejecutó un banco de pruebas compuesto por 17 consultas estructuradas según distintas intenciones de búsqueda.

Tabla 1. Resumen de métricas globales.

Métrica	Valor global	Diagnóstico
Precision	0.671	Moderada-Alta: el sistema muestra una mejora en el filtrado de ruido, aunque sigue viéndose afectado por la escasez de documentos para ciertas consultas
Recal	0.935	Excelente: el sistema recupera la gran mayoría de los elementos relevantes indexados, rompiendo la exhaustividad absoluta debido a un fallo crítico puntual
F1-Score	0.723	Sólido: representa un balance equilibrado y una evolución positiva en la armonía de la recuperación general.
NDCG	0.932	Sobresaliente: El ordenamiento y la ganancia acumulada degradada demuestran que los elementos verdaderamente útiles se sitúan casi siempre al inicio.
MRR	0.941	Excepcional: en las consultas exitosas, el primer elemento relevante devuelto se ubica de forma invariante en la primera posición.

Análisis por tipo de intención de búsqueda

Consultas temáticas y de metadatos (Q1, Q2, Q3, Q4, Q8, Q9, Q10, Q11, Q12, Q13, Q14): Es el escenario con mejor desempeño. En casi la totalidad de estas consultas (a excepción de ligeras variaciones de NDCG en Q11 y Q12), el MRR es un perfecto 1.000. El recuperador demuestra una precisión milimétrica al ordenar los resultados; siempre coloca el contenido más relevante en el puesto número uno de la interfaz. Llama la atención el caso de Q3 posee una Precision de apenas 0.300, pero un NDCG y MRR de 1.000. Esto denota que el sistema recuperó con éxito los únicos 3 documentos relevantes existentes en las primeras 3 posiciones, y la penalización en precisión es un mero artefacto matemático causado por la obligación de completar el Top 10 con resultados no relevantes

Búsquedas de entidades nombramiento único (Q5, Q6, Q7): Al igual que en el escenario de metadatos escasos, la Precision se sitúa en niveles mínimos (0.100 a 0.200), mientras que el MRR y el NDCG permanecen estables en 1.000. El sistema ubica de forma inmediata la serie exacta buscada por el usuario en la primera posición. La caída de la precisión no refleja una deficiencia real en la experiencia del usuario, sino una limitación de la métrica fija K cuando el tamaño del conjunto de relevancia del Ground Truth es menor que K ($|\text{Relevant}| < 10$).

Consultas de lenguaje natural complejo (Q15, Q16, Q17): Este bloque exhibe un comportamiento polarizado de éxito absoluto y fracaso total. Mientras que Q15 y Q17 logran métricas perfectas o casi perfectas, Q16 sufre un colapso absoluto, registrando 0.000 en todas sus métricas. La consulta Q16 representa la única razón por la cual el Recall global del sistema cayó a 0.941. El recuperador fue completamente incapaz de enlazar la semántica conversacional de la consulta con los documentos de la base de datos dentro del Top 10. Esto evidencia una falta de robustez ante descripciones indirectas o coloquiales de "larga cola", donde no se mencionan palabras clave explícitas del título.

6 Estructura de la Implementación

El sistema CulturaSearch está organizado en módulos independientes pero integrados, cada uno con una responsabilidad específica dentro del flujo general de recuperación de información.

- crawler/: descubre Urls de películas y series a partir de fuentes semilla.
- scraper/: extrae y estructura los metadatos de las páginas descubiertas.
- index/: construye y limpia el índice léxico invertido.
- bd/: almacena el índice vectorial, embeddings y metadatos asociados.
- neural_based_model/: implementa el recuperador neuronal y el re-ranking.
- positioning_module/: gestiona puntuaciones combinadas y estrategias de posicionamiento.
- rag_module/: coordina la recuperación aumentada con generación de texto.
- web_search/: permite expansión web cuando la confianza local es baja.
- recommendation_module/: gestiona el perfil del usuario y la personalización.
- evaluation_module/: mide el desempeño del sistema con métricas de recuperación.
- estadísticas/: contiene scripts para análisis cuantitativo del corpus.
- app.py: implementa la interfaz visual del sistema.
- main.py: actúa como lanzador general para los componentes principales.

7 Opinión Crítica del Proyecto Implementado

Desde una perspectiva crítica, el proyecto presenta una evolución sólida y coherente respecto a una recuperación básica de información. Entre sus principales bondades se destaca la integración de múltiples enfoques complementarios: recuperación semántica

con embeddings, señales léxicas, re-ranking, expansión web, interfaz visual y personalización basada en el perfil del usuario. Esta combinación convierte al sistema en una plataforma más completa y cercana a escenarios reales de búsqueda y exploración de contenido.

No obstante, también se identifican insuficiencias. La primera de ellas es la dependencia de componentes externos, como Ollama y la conectividad web, lo cual puede afectar la disponibilidad y la latencia del sistema. Además, la complejidad de la arquitectura incrementa el costo de mantenimiento y hace necesario documentar con precisión cada módulo para facilitar su evolución futura.

8 Deficiencias Detectadas por el Equipo y Posibles Soluciones

- Dependencia del modelo local: Si Ollama falla, el sistema deja de responder. Se propone añadir mecanismos de respaldo para que la funcionalidad se degrade sin interrumpirse por completo.
- Riesgos de la expansión web: La búsqueda en internet depende de la red y de fuentes externas. Se sugiere mejorar el uso de caché, reforzar la detección de errores y limitar cuándo se activa la búsqueda online.
- Personalización limitada al inicio: El sistema personaliza mejor tras varias interacciones; al principio el perfil es pobre. Una solución sería incluir una configuración inicial o preferencias básicas para construir un perfil mínimo.

9 Estadísticas Básicas del Corpus Recopilado

9.1 Tamaño General del Corpus

Tras el proceso de crawling y scraping realizado, se ha consolidado un corpus con las siguientes métricas de volumen:

- Cantidad total de documentos: 2684.
- Documentos tipo película: 1541.
- Documentos tipo serie: 1143




Fig. 1. Distribución comparativa entre películas y series de TV recopiladas en el dominio de cultura y entretenimiento.

9.2 Análisis de Longitud Textual

Para garantizar que el modelo de recuperación semántica (embeddings) reciba suficiente contexto, se analizó la extensión de la cadena de texto consolidada título + sinopsis. Los resultados actualizados del corpus son:

- Promedio de palabras por documento: 138.90
- Promedio de caracteres por documento: 829.92
- Mínimo de palabras en un documento: 1
- Máximo de palabras en un documento: 520

9.3 Diversidad y Riqueza del Corpus

El dominio de cultura y entretenimiento presenta una alta variabilidad en sus atributos. El análisis de los metadatos extraídos de las fuentes especializadas arroja los siguientes indicadores de diversidad, fundamentales para validar la robustez del sistema de recuperación:

Distribución Temática y Geográfica

- Géneros detectados: Se identificaron 34 categorías únicas. El corpus presenta una marcada predominancia de los géneros Drama (1102 documentos) y Acción (666), seguidos por Comedia (598), Suspense (495) y Aventura (441).
- Alcance Global: El sistema integra obras de 41 países de origen. Destaca la hegemonía de producciones de Estados Unidos (582), seguida por una presencia significativa de España (128) y Gran Bretaña (86).




Fig. 2. Distribución de los cinco géneros principales segmentados por país de origen. La visualización permite confirmar la diversidad del corpus y la representatividad de cada categoría dentro de los mercados cinematográficos líderes.

Entidades y Personalidades

- Directores: Se identificaron 1190 directores únicos
- Elenco: El corpus cuenta con una base de 4761 actores únicos.

Valoración y Calidad (Ratings)

- Rating promedio: La calificación media de las obras en el corpus es de 3.55.
- Rango de valoración: El conjunto de datos abarca desde obras de alto impacto crítico (4.7) hasta producciones de menor recepción (1.2).




Fig. 3. Distribución de frecuencias de las calificaciones en el corpus.

9.4 Análisis del Rango Temporal

El corpus recolectado presenta una ventana cronológica que permite evaluar el desempeño del sistema ante diferentes contextos de producción audiovisual:

- El año mínimo detectado fue 1944 y el año máximo fue 2028

10 Fuentes Bibliográficas

1. Mitra, B., Craswell, N.: An introduction to neural information retrieval. *Foundations and Trends in Information Retrieval* (2018)
2. NLTK Project: NLTK Documentation: Spanish Snowball Stemmer, <http://www.nltk.org>
3. Reimers, N., Gurevych, I.: Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (2019)
4. Hugging Face: Documentation: paraphrase-multilingual-MiniLM-L12-v2, <http://huggingface.co>